

RAG检索增强生成项目知识点

一、RAG 基础知识点：通用公理（所有 RAG 系统通用，面试必背核心）

（一）RAG 核心定义公理

1. **RAG = Retrieval-Augmented Generation 检索增强生成** 本质：先检索外部私有知识库，再把检索到的上下文拼接进大模型 Prompt，最后让 LLM 生成答案。
2. **根本解决两大 LLM 原生缺陷（第一公理，面试第一问必考）**
 - 缺陷 1：知识截止时间固定（模型训练后新知识无法知晓）
 - 缺陷 2：幻觉（Hallucination）：凭空编造不存在的事实、数据、文档 RAG 公理：外部检索的真实文档作为事实约束，大幅降低幻觉，支持实时 / 私有数据问答
3. **RAG 不可替代的适用边界公理** 只要满足以下任意一条，必须用 RAG，纯微调 / Prompt 工程无法解决：
 - 有企业私有文档（内部手册、合同、数据库、工单，不在 LLM 训练集）
 - 知识高频更新（实时新闻、每日业务数据、政策变动）
 - 需要输出可溯源、可引用原文的答案（合规、审计场景）
 - 不允许模型编造事实，对答案准确性要求极高

（二）标准 RAG 四阶段流水线公理（所有架构底层通用，万能框架）

任何 RAG 系统都拆成两大模块：离线文档预处理流水线 + 在线问答推理流水线

阶段 1：离线构建向量库（仅执行一次 / 增量更新）

1. 文档加载 Load：读取 PDF/MD/Word/TXT/ 数据库 / 网页等原始文件
2. 文本分割 Split/Chunk：长文档切小块（Chunk 切片，核心难点）
3. 向量化 Embedding：文本块转为稠密浮点向量（Embedding 向量）
4. 向量存储 Vector Store：向量 + 原文块存入向量数据库，建立索引

阶段 2：在线用户问答（实时执行）

1. 用户 Query 向量化：把用户提问转成向量
2. 相似度检索 Retrieval：向量库匹配最相似 Top-N 文本块
3. Prompt 拼接 Augment：Query + 检索到的上下文 组装完整提示词
4. LLM 生成 Generation：大模型基于检索上下文输出回答

（三）关键底层通用公理（面试高频深挖）

1. **向量相似度公理** 语义相近的文本，其 Embedding 向量在高维空间距离更近；通用距离计算方式：
 - 余弦相似度 Cosine Similarity（RAG 行业标准，不受文本长度影响）

- L2 欧氏距离、内积（部分向量库专用）

2. **Chunk 切片核心公理**

- Chunk 不能太小：丢失完整语义，检索上下文断裂
- Chunk 不能太大：向量语义混杂，检索精度暴跌，同时超出 LLM 上下文窗口
- 通用优化：**重叠切片 Overlap**，块与块保留重叠文本，解决跨块语义割裂

3. **检索质量决定 RAG 上限公理** LLM 只是“语言润色器”，如果检索到错误、无关文档，无论多强的大模型都会输出错误答案；行业共识：**检索召回精度 > 大模型能力**

4. **幻觉抑制公理** Prompt 必须增加约束：**仅使用提供的检索上下文回答，上下文无信息则如实告知不知道，禁止编造**

5. **基础 RAG 缺陷公理（进阶面试必问）** 朴素基础 RAG 存在大量短板，衍生进阶 RAG 优化方案：
- 问题：简单向量检索只匹配表层语义，忽略深层意图 → 优化：Query 改写、多查询检索
 - 问题：长文档单轮检索信息不全 → 优化：递归检索、父文档检索
 - 问题：检索大量冗余文本占用上下文窗口 → 优化：重排序 Rerank
 - 问题：历史对话丢失上下文 → 优化：对话记忆 RAG

（四）基础 RAG vs 微调 Fine-tune 核心对比公理（面试高频对比题）

表格

维度	RAG 检索增强	LLM 微调 Fine-tune
数据更新	实时增量，新增文档直接入库，无需重训	更新数据必须重新训练，成本极高
私有数据安全	文档不送入模型训练，仅推理时临时传入	私有数据参与训练，存在数据泄露风险
成本	算力成本极低，小机器可部署	高显存、高算力、高额训练费用
可溯源性	答案绑定原文片段，可引用来源	模型知识内化，无法追溯依据
适用场景	海量动态私有文档、合规要求高	固定风格、固定输出格式、少量标准化数据

二、RAG 开发必备库、API、向量数据库（分 4 大类：文档处理、Embedding、向量库、LLM 调用）

（一）文档加载 & 文本分割库（离线预处理阶段）

1. LangChain（RAG 一站式框架，面试最高频）

- 核心功能：封装全链路 RAG 流水线，统一接口对接所有文档解析器、Embedding、向量库、LLM
- 核心模块：

- DocumentLoaders: PDFLoader、TextLoader、WebBaseLoader、DirectoryLoader (批量读文件夹)
- TextSplitter: RecursiveCharacterTextSplitter (递归字符分割, 工业通用)、MarkdownTextSplitter、SemanticChunker (语义切片进阶方案)
- Chains: RetrievalQA、ConversationalRetrievalChain (问答链、对话 RAG 链)
- Memory: ConversationBufferMemory 对话记忆

2. LlamaIndex (另一大主流 RAG 框架, 侧重检索优化)

- 定位: 比 LangChain 检索功能更强, 原生支持父文档检索、多索引、Rerank
- 适用场景: 海量长文档、高精度检索需求项目
- 核心组件: SimpleDirectoryReader、SentenceSplitter、VectorStoreIndex

3. PyPDF2 / pdfplumber

- 功能: 本地 PDF 解析, 提取文字; pdfplumber 支持表格提取 (合同、报表类文档必备)

4. python-docx / python-pptx

- 功能: 解析 Word、PPT 文档, 提取正文文本

5. Unstructured.io

- 功能: 万能文档解析, 支持 PDF/Word/ 图片 OCR/Excel, 自动清理换行、乱码、页眉页脚
- 提供本地开源库 + 云端 API 两种模式

(二) Embedding 向量化工具 (文本转向量, 分本地开源模型 / 云端 API)

云端 Embedding API (开箱即用, 无需显卡, 企业快速落地)

1. OpenAI Embedding API

- 模型: text-embedding-ada-002、text-embedding-3-small/large
- 优点: 语义理解强, 通用场景精度高; 缺点: 付费、有网络依赖、数据外传风险

2. 阿里通义千问 Embedding、百度千帆 Embedding、智谱 Embedding、讯飞 Embedding

- 国内大模型厂商接口, 中文语义适配更好, 国内合规无跨境数据问题

3. Cohere Embedding API

- 擅长长文本向量, 海外竞品

本地开源 Embedding 库 (私有化部署, 无数据出境, 面试私有化项目必考)

1. Sentence-Transformers (行业标准本地向量库)

- 功能: 一键加载开源向量模型 (bge、m3e、all-MiniLM), 本地生成向量, 纯 Python 轻量

- 主流中文模型：BGE-small-zh、m3e-base、e5-zh（面试必提中文向量模型）

2. FlagEmbedding

- BGE 系列模型官方配套库，支持长文本、Rerank 重排序模型一体化

3. ModelScope / Hugging Face Transformers

- 底层框架，手动加载任意向量大模型，自由度最高，适合自定义微调向量模型

（三）向量数据库 Vector Store（存储向量 + 检索，分轻量本地 / 分布式生产级）

1. 轻量本地向量库（开发调试、小型项目，现场编程常用）

1. ChromaDB

- LangChain/LlamaIndex 原生适配，零配置，内存 / 本地文件存储，无需启动服务
- 面试现场编程首选，代码最简，适合演示最小 RAG Demo

2. FAISS（Meta 开源）

- 纯 CPU/GPU 极速向量检索，无持久化文件（需自己存原文），适合大规模离线检索

3. SQLite-VSS

- 基于 SQLite 的向量扩展，不用额外服务，小型轻量化部署

2. 生产级分布式向量库（企业线上项目，面试项目经验必问）

1. Milvus / Zilliz

- 国内最主流生产向量库，分布式、分片、海量百万 / 亿级向量，支持 GPU 加速、动态增量

2. Qdrant

- 开源高性能向量库，自带 API，支持 payload 存储（直接存原文，无需额外数据库）

3. Pinecone（海外云向量库）

- 全托管云端向量服务，不用运维，海外项目常用

4. Weaviate

- 自带内置 Embedding 与 LLM 模块，一体化知识库平台

（四）LLM 大模型调用库 / API（生成回答阶段）

云端 LLM API

1. OpenAI SDK（openai python 包）

- 调用 gpt-3.5/4，LangChain 底层封装依赖该库

2. 国内厂商 SDK：dashscope（阿里）、zhipuai（智谱）、qianfan（百度千帆）、iflytek（讯飞）

- 国内私有化云 API，满足等保合规

本地开源 LLM 运行库（私有化离线 RAG 面试重点）

1. Ollama（面试高频！本地一键跑大模型）

- 一句话拉取 llama3、qwen、glm 等开源大模型，提供本地 HTTP 接口

- 优势：极低上手成本，本地 RAG Demo 标配，现场编程常用
2. Transformers + accelerate
 - Hugging Face 底层，手动加载本地大模型，显存精细化控制
 3. vLLM
 - 高吞吐推理框架，线上部署开源大模型，提升并发速度
 4. Llama.cpp
 - 轻量化 CPU 跑大模型，低配机器离线部署

（五）进阶优化配套库（进阶 RAG 面试加分项）

1. Rerank 重排序：FlagReranker、Cohere Rerank API、Cross-Encoder 作用：初次检索 Top10 文档后，用交叉模型重新打分过滤无关文本，大幅提升精度
2. 对话记忆：LangChain Memory、Redis（分布式存储对话历史）
3. 后端接口封装：FastAPI、Flask（把 RAG 封装成 HTTP 接口，前后端联调）
4. 前端展示：Gradio、Streamlit（快速做可视化 RAG 网页 Demo，面试演示必备）
5. OCR 文本识别：PaddleOCR、Tesseract（图片 / PDF 扫描件文字提取）